Betriebssysteme 2 | BSys2

Zusammenfassung

```c
int *px = &x; // &x = Adresse des ints, * = Pointer-Bezeichner
int y = *px;  // *px = Wert einer int-Adresse, y = 5, * = Dereferenzoperator
```

4096	2048	1024	512	256	128	64	32	16	8	4	2	1
2^{12}	2^{11}	2^{10}	2^{9}	2^{8}	2^{7}	2^{6}	2^{5}	2^{4}	2^{3}	2^{2}	2^{1}	2^{0}
$10\,00_h$	$8\,00_h$	$4\,00_h$	$2\,00_h$	$1\,00_h$	80_h	40_h	20_h	10_h	8_h	4_h	2_h	1_h

1'048'576	65'536	4'096	256	16	1
16^5	16^4	16^3	16^2	16^1	16^0
$10\,00\,00_h$	$01\,00\,00_h$	$00\,10\,00_h$	$00\,01\,00_h$	$00\,00\,10_h$	$00\,00\,01_h$

0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0000	0001	0010	0011	0100	0101	0110	0111	1000	1001	1010	1011	1100	1101	1110	1111

1. BETRIEBSSYSTEM API

Aufgaben: Abstraktion, Portabilität, Ressourcenmanagement & Isolation der Anwendungen, Benutzerverwaltung und Sicherheit.

Privilege Levels: ***Kernel-Mode*** *(darf alles ausführen, Ring 0)*, ***User-Mode*** *(darf nur beschränkte Menge an Instruktionen ausführen, Ring 3)*

Kernels: ***Microkernel*** *(nur kritische Teile laufen im Kernel-Mode)*, ***Monolithisch*** *(meiste OS, weniger Wechsel, weniger Schutz)*, ***Unikernel*** *(Kernel ist nur ein Programm)*

`syscall` veranlasst den Prozessor, in den Kernel Mode zu schalten. Jede OS-Kernel-Funktion hat einen Code, der einem Register übergeben werden muss. *(`exit` hat den Code 60)*

ABI: Application Binary Interface, Abstrakte Schnittstelle mit platformunabhängigen Aspekten.

API: Application Programming Interface, Konkrete Schnittstellen, Calling Convention, Abbildung von Datenstrukturen. ***Linux-Kernels*** sind API-, aber nicht ABI-kompatibel. *(C-Wrapper-Funktionen)*

POSIX: Portable Operating System Interface. Sammlung von IEEE Standards, welche die Kompatibilität zwischen OS gewährleistet. Windows ist nicht POSIX-konform.

1.1. PROGRAMMARGUMENTE

`clang -c abc.c -o abc.o`. Die Shell teilt Programmargumente in Strings auf *(Trennung durch Leerzeichen, sonst Quotes)*. **Calling Convention:** OS schreibt Argumente als null-terminierte Strings in den Speicherbereich des Programms. Zusätzlich legt das OS ein Array `argv` an, dessen Elemente jeweils auf das erste Zeichen eines Arguments zeigen. Die Art und Weise, wie das gehandhabt wird, ist die Calling Convention. Werden explizit angegeben, nützlich für Informationen, die bei jedem Aufruf anders sind.

```c
int main(int argc, char ** argv) { ... } // argv[0] = program path
```

1.2. UMGEBUNGSVARIABLEN

Strings, die mindestens ein `Key=Value` enthalten *(`OPTER=1, PATH=/home/ost/bin`)*. Der Key muss einzigartig sein. Unter POSIX verwaltet das OS die Umgebungsvariablen innerhalb jedes laufenden Prozesses. Werden initial festgelegt. Das OS legt die Variablen als ein null-terminiertes Array von Pointern auf null-terminierte Strings ab. Unter C zeigt die Variable `extern char **environ` darauf. Sollte nur über untenstehende Funktionen manipuliert werden. Werden implizit bereitgestellt, nützlich für Informationen, die bei jedem Aufruf gleich sind.

- **Abfragen einer Umgebungsvariable:** `char *value = getenv("PATH");`
- **Setzen einer Umgebungsvariable:** `int ret = setenv("HOME", "/usr/home", 1);`
- **Entfernen einer Umgebungsvariable:** `int ret = unsetenv("HOME");`
- **Hinzufügen einer Umgebungsvariable :** `int ret = putenv("HOME=/usr/home");` *(gefährlich wegen Pointer auf `NULL`)*

Grössere Konfigurationsinformationen sollten über ***Dateien*** übermittelt werden.

2. DATEISYSTEM API

Applikationen dürfen nie annehmen, dass Daten gültig sind.

Arbeitsverzeichnis: Bezugspunkt für relative Pfade, jeder Prozess hat eines *(`getcwd()`, `chdir()`: nimmt String, `fchdir()`: nimmt File Deskriptor)*.

Pfade: Absolut *(beginnt mit /)*, Relativ *(beginnt nicht mit /)*, Kanonisch *(Absolut, ohne «.» und «..», `realpath()`)*

- ***`NAME_MAX`:*** Maximale Länge eines Dateinamens (exklusive terminierender Null)
- ***`PATH_MAX`:*** Maximale Länge eines Pfads (inklusive terminierender Null) *(beinhalt. Wert von `NAME_MAX`)*
- ***`_POSIX_NAME_MAX`:*** Minimaler Wert von `NAME_MAX` nach POSIX *(14)*
- ***`_POSIX_PATH_MAX`:*** Minimaler Wert von `PATH_MAX` nach POSIX *(256)*

```c
// Gibt Arbeitsverzeichnis aus
int main (int argc, char ** argv) { char *wd = malloc(PATH_MAX);
getcwd(wd, PATH_MAX); printf("Current WD is %s", wd); free(wd); return 0; }
```

Zugriffsrechte: Je 3 Permission-Bits für Owner, Gruppe und andere Benutzer. Bits sind: **r**ead, **w**rite, e**x**ecute: `r=4, w=2, x=1` ***Beispiel:*** `0740` oder `rwx r-- ---` *(Owner hat alle Rechte, Gruppe kann lesen, andere haben keine Rechte)*. **POSIX:** `S_IRWXU = 0700`, `S_IWUSR = 0200`, `S_IRGRP = 0040`, `S_IXOTH = 0001`. Werden mit | verknüpft.

POSIX-API: für direkten Zugriff, alle Dateien sind rohe Binärdaten. **C-API:** für direkten Zugriff auf Streams. **POSIX FILE API:** für direkten, unformatierten Zugriff auf Inhalt der Datei. Nur für Binärdaten verwenden. **`errno`:** Makro oder globale Variable vom typ `int`. Sollte direkt nach Auftreten eines Fehlers aufgerufen werden.

```c
if (chdir("docs") < 0) { if (errno == EACCESS) { printf("Error: Denied"); }}
```

`strerror` gibt die Adresse eines Strings zurück, der den Fehlercode `code` textuell beschreibt. **`perror`** schreibt `text` gefolgt von einem Doppelpunkt und vom Ergebnis von `strerror(errno)` auf den Errorstream.

2.1. FILE-DESCRIPTOR (FD)

Files werden in der POSIX-API über FD's repräsentiert. Gilt nur ***innerhalb eines Prozesses***. Returnt ***Index in Tabelle*** aller geöffneter Dateien im Prozess → Enthält ***Index in systemweite Tabelle*** → Enthält Daten zur Identifikation der Datei. ***`STDIN_FILENO = 0`:*** standard input, ***`STDOUT_FILENO = 1`:*** standard output, ***`STDERR_FILENO = 2`:*** standard error

`int open (char *path, int flags, ...)`: ***öffnet*** eine Datei. Erzeugt FD auf Datei an `path`. `flags` gibt an, **wie** die Datei geöffnet werden soll:

- ***`O_RDONLY`:*** nur lesen,
- ***`O_RDWR`:*** lesen und schreiben,
- ***`O_CREAT`:*** Erzeuge Datei, wenn sie nicht existiert,
- ***`O_APPEND`:*** Setze Offset ans Ende der Datei vor jedem Schreibzugriff,
- ***`O_TRUNC`:*** Setze Länge der Datei auf 0

`int close (int fd)`: ***schliesst*** Datei bzw. ***dealloziert*** den FD. Kann dann wieder für andere Dateien verwendet werden. Wenn FD's nicht geschlossen werden, kann das FD-Limit erreicht werden, dann können keine weiteren Dateien mehr geöffnet werden. Wenn mehrere FDs die gleiche Datei öffnen, können sie sich gegenseitig Daten überschreiben.

```c
int fd = open("myfile.dat", O_RDONLY);
if (fd < 0) { /* error handling */ } /* read data; */ close(fd);
```

`ssize_t read(int fd, void * buffer, size_t n)`:
kopiert die nächsten n Bytes am aktuellen Offset ***von fd in den Buffer***.
`ssize_t write(int fd, void * buffer, size_t n)`:
kopiert die nächsten n Byte ***vom `buffer` an den aktuellen Offset von `fd`***

```c
#define N 32
char buf[N]
char spath[PATH_MAX]; // source path
char dpath[PATH_MAX]; // destination path
// ... gets paths from somewhere
int src = open(spath, O_RDONLY);
int dst = open(dpath, O_WRONLY | O_CREAT, S_IRWXU);
ssize_t read_bytes = read(src, buf, N);
write(dst, buf, read_bytes); // if file closed early, only write as many bytes
close(src);                  // as have been read from the file
close(dst);
```

`off_t lseek(int fd, off_t offset, int origin)`:
Springen in einer Datei. Verschiebt den Offset und gibt den neuen Offset zurück. ***`SEEK_SET`:*** Beginn der Datei, ***`SEEK_CUR`:*** Aktueller Offset, ***`SEEK_END`:*** Ende der Datei. ***`lseek(fd, 0, SEEK_CUR)`*** gibt aktuellen Offset zurück, ***`lseek(fd, 0, SEEK_END)`:*** gibt die Grösse der Datei zurück.

`ssize_t pread/pwrite(int fd, void * buffer, size_t n, off_t offset)`:
Lesen und Schreiben ohne Offsetänderung. Wie `read` bzw. `write`. Statt des Offsets von `fd` wird der zusätzliche Parameter `offset` verwendet.

2.1.1. Unterschiede Windows und POSIX

Bestandteile von Pfaden werden durch ***Backslash*** (\) getrennt, ein ***Wurzelverzeichnis pro*** Datenträger/Partition, andere File-Handling-Funktionen.

2.2. C STREAM API

Unabhängig vom Betriebssystem, Stream-basiert, gepuffert oder ungepuffert, hat einen eigenen File-Position-Indicator (FPI).

Streams: `FILE *` enthält ***Informationen über einen Stream***. Soll nicht direkt verwendet oder kopiert werden, sondern nur über von C-API erzeugte Pointer.

`FILE * fopen(char const *path, char const *mode)`: ***Öffnen eine Datei.*** Erzeugt `FILE`-Objekt für Datei an `path`. Flags für `mode`: ***"r"*** *(Datei lesen)*, ***"w"*** *(in neue oder bestehende geleerte Datei schreiben)*, ***"a":*** *(in neue oder bestehende Datei anfügen)*, ***"r+:*** *(Datei lesen & schreiben)*, ***"w+"*** *(neue oder geleerte bestehende Datei lesen & überschreiben)*, ***"a+"*** *(neue oder bestehende Datei lesen & an Datei anfügen)*. Gibt Pointer auf erzeugtes `FILE`-Objekt zurück oder 0 bei Fehler. `FILE * fdopen(int fd, char const * mode)` ist gleich, aber statt Pfad wird direkt der FD übergeben. `int fileno (FILE *stream)` gibt FD zurück. Nach API-Wechsel die vorherige API nicht mehr verwenden.

`int fclose(FILE *file)`: ***Schliesst eine Datei.*** Ruft `fflush()` auf *(schreibt Inhalt aus Speicher in die Datei)*, schliesst den Stream, entfernt `file` aus Speicher und gibt 0 zurück wenn OK, andernfalls `EOF`.

`int fgetc(FILE *stream)`: ***Liest*** das nächste Byte und erhöht FPI um 1.

`char * fgets(char *buf, int n, FILE *stream)` liest bis zu $n-1$ Zeichen aus `stream`.

`int ungetc(int c, FILE *stream)`: ***Lesen rückgängig machen.*** Nutzt Unget-Stack.

`int fputc(int c, FILE *stream)`: ***Schreibt c in eine Datei.***

`int fputs(char *s, FILE *stream)`: Schreibt die Zeichen vom String s bis zur terminierenden 0 in `stream`.

2.2.1. Dateiende und Fehler:

`int feof(FILE *stream)` gibt 0 zurück, wenn Dateiende ***noch nicht*** erreicht wurde

`int ferror(FILE * stream)` gibt 0 zurück, wenn ***kein*** Fehler auftrat.

2.2.2. Manipulation des File-Position-Indicator (FPI):

`long ftell(FILE *stream)` gibt den gegenwärtigen FPI zurück, `int fseek (FILE *stream, long offset, int origin)` setzt den FPI, analog zu `lseek`, `int rewind (FILE *stream)` setzt den Stream zurück.

3. PROZESSE

Prozesse *(aktiv)* sind die ***Verwaltungseinheit*** des OS für Programme *(passiv)*. Jedem Prozess ist ein ***virtueller Adressraum*** zugeordnet.

Ein Prozess umfasst das ***Abbild eines Programms*** im Hauptspeicher *(text section)*, die ***globalen Variablen des Programms*** *(data section)*, Speicher für den ***Heap*** und Speicher für den ***Stack***.

Process Control Block (PCB): Das Betriebssystem hält Daten über jeden Prozess in jeweils einem ***PCB*** vor. Speicher für alle Daten, die das OS benötigt, um die Ausführung des Prozesses ins Gesamtsystem zu integrieren, u.a.: Diverse IDs, Speicher für Zustand, Scheduling-Informationen, Daten zur Synchronisation, Security-Informationen etc.

Interrupts: ***Kontext*** des aktuellen Prozesses muss im dazugehörigen PCB gespeichert werden *(context save)*: Register, Flags, Instruction Pointer, MMU-Konfiguration. ***Interrupt-Handler*** überschreibt den Kontext. Anschliessend wird Kontext aus PCB wiederhergestellt *(context restore)*.

Prozess-Erstellung: Das OS erzeugt den Prozess und lädt das Programm in den Prozess. Unter POSIX getrennt, unter Windows eine einzige Funktion.

Prozess-Hierarchie: Baumstruktur, startet bei Prozess 1.

3.1. PROZESS-API

`pid_t fork(void)` erzeugt ***exakte Kopie*** (C) als Kind des Prozesses (P), mit eigener Prozess-ID (>0). Die Funktion führt in ***beiden*** Prozessen den Code an derselben Stelle fort.

`void exit(int code)`: Beendet das Programm und gibt `code` zurück.

`pid_t wait(int *status)`: unterbricht Prozess, bis Child beendet wurde.

`pid_t waitpid (pid_t pid, int *status, int options)`: wie `wait()`, aber `pid` bestimmt, auf welchen Child-Prozess man warten will *(> 0 = Prozess mit dieser ID, −1 = irgendeinen Child-Prozess, 0 = alle C mit der gleichen Prozessgruppen-ID)*.

```c
void spawn_worker (...) {
  if (fork() == 0) { /* do something in worker process; */ exit(0); }
}
for (int i = 0; i < n; ++i) { spawn_worker(...); }
// ... do something in parent process
do { pid = wait(0); } while (pid > 0 || errno != ECHILD); //wait for all children
```

`exec()`-Funktionen: Jede davon ***ersetzt*** im gerade laufenden Prozess das Programmimage ***durch ein anderes***. Programmargumente müssen spezifiziert werden. *(`..l` als Liste, `..v` als Array)*

Aufrufen der Executable	*Zustand der Environment-Variabeln*	*Programmargumente als Liste*	*Programmargumente als Array*
Angabe des Pfads	mit neuem Environment	`execle()`	`execve()`
	mit altem Environment	`execl()`	`execv()`
Suche über `PATH`		`execlp()`	`execvp()`

3.1.1. Zombie- & Orphan-Prozesse

C ist zwischen seinem Ende und dem Aufruf von `wait()` durch P ein Zombie-Prozess. ***Dauerhafter Zombie-Prozess:*** P ruft wegen Fehler `wait()` nie auf. ***Orphan-Prozess:*** P wird vor C beendet. P kann somit nicht mehr auf C warten, was bei Beendung von C in einem dauerhaften Zombie resultiert. Wenn P beendet wird, werden deshalb alle C an Prozess mit `pid=1` übertragen, der `wait()` in einer Endlosschleife aufruft.

`unsigned int sleep (unsigned int seconds)`: ***unterbricht*** Ausführung, bis eine Anzahl Sekunden ungefähr verstrichen ist. Gibt vom Schlaf noch vorhandene Sekunden zurück.

`int atexit (void (*function)(void))`: Registriert Funktionen für Aufräumarbeiten vor Ende.

`pid_t getpid()/getppid()`: geben die (Parent-)Prozess-ID zurück.

4. PROGRAMME UND BIBLIOTHEKEN

`C-Quelle` → `Präprozessor` → `Bereinigte C-Quelle` → `Compiler` → `Assembler-Datei` → `Assembler` → `Objekt-Datei` → `Linker` → `Executable`

Präprozessor: Die Ausgabe des Präprozessors ist eine reine C-Datei (Translation-Unit) ohne Makros, Kommentare oder Präprozessor-Direktiven. ***Linker:*** Der Linker verknüpft Objekt-Dateien (und statische Bibliotheken) zu Executables oder dynamischen Bibliotheken. ***Loader*** lädt Executables und eventuelle dynamische Bibliotheken dieser in den Hauptspeicher.

4.1. ELF (EXECUTABLE AND LINKING FORMAT)

Binär-Format, das Kompilate spezifiziert. Besteht aus ***Linking View*** *(wichtig für Linker, für Object-Files und Shared Objects)* und ***Execution View*** *(wichtig für Loader, für Programme und Shared Objects)*.

Struktur: Besteht aus ***Header***, ***Programm Header Table*** *(execution view)*, ***Segmente*** *(execution view)*, ***Section Header Table*** *(linking view)*, ***Sektionen*** *(linking view)*

4.2. SEGMENTE UND SEKTIONEN

Segmente und ***Sektionen*** sind eine andere Einteilung für die gleichen Speicherbereiche. View des ***Loaders*** sind die ***Segmente***, view des ***Compilers*** die ***Sektionen***. Definieren «gleichartige» Daten. Der ***Linker*** vermittelt zwischen beiden Views.

Header: Beschreibt den ***Aufbau*** der Datei: Typ, 32/64-bit, Encoding, Maschinenarchitektur, Entrypoint, Infos zu den Einträgen in PHT und SHT.

Segment/Program Header Table und Segmente: Tabelle mit n Einträgen, jeder Eintrag *(je 32 Byte)* beschreibt ein Segment *(Typ und Flags, Offset und Grösse, virtuelle Adresse und Grösse im Speicher - kann unterschiedlich zur Dateigrösse sein)*. Ist Verbindung zwischen Segmenten im RAM und im File. Definiert, wo ein Segment liegt und wohin der Loader es im RAM laden soll.
Segmente werden vom ***Loader*** dynamisch ***zur Laufzeit*** verwendet.

Section Header Table und Sektionen: Tabelle mit m Einträgen ($\neq n$). Jeder Eintrag *(je 40 Byte)* beschreibt eine Sektion *(Name, Section-Typ, Flags, Offset und Grösse, ...)*. Werden vom ***Linker*** verwendet: Verschmilzt Sektionen und erzeugt ausführbares Executable.

String-Tabelle: Bereich in der Datei, der nacheinander ***null-terminierte Strings enthält***. Strings werden relativ zum Beginn der Tabelle referenziert.

Symbole & Symboltabelle: Die Symboltabelle enthält jeweils ***einen Eintrag je Symbol*** *(16 Byte: 4B Name, 4B Wert, 4B Grösse, 4B Info)*.

4.3. BIBLIOTHEKEN

Statische Bibliotheken: Archive von Objekt-Dateien. Name: `lib<name>.a`, referenziert wird nur `<name>`. ***Linker*** behandelt statische Bibliotheken wie ***mehrere Objekt-Dateien***. Ursprünglich gab es ***nur statische Bibliotheken*** *(Einfach zu implementieren, aber Funktionalität fix)*.

Dynamische Bibliotheken: Linken erst zur Ladezeit bzw. Laufzeit des Programms. Höherer Aufwand, jedoch austauschbar. Executable enthält nur Referenz auf Bibliothek. **Vorteile:** Entkoppelter Lebenszyklus, Schnellere Ladezeiten durch Lazy Loading, Flexibler Funktionsumfang.

4.4. POSIX SHARED OBJECTS API

`void * dlopen (char * filename, int mode)`: ***öffnet*** eine dynamische Bibliothek und gibt ein Handle darauf zurück. `mode` ist einer der folgenden Werte:

- ***`RTLD_NOW`:*** Alle Symbole werden beim Laden gebunden
- ***`RTLD_LAZY`:*** Symbole werden bei Bedarf gebunden
- ***`RTLD_GLOBAL`:*** Symbole können beim Binden anderer Objektdateien verwendet werden
- ***`RTLD_LOCAL`:*** Symbole werden nicht für andere Objektdateien verwendet

`void * dlsym (void * handle, char * name)`: gibt die ***Adresse des Symbols*** `name` aus der mit `handle` bezeichneten ***Bibliothek*** zurück. Keine Typinformationen *(Variabel? Funktion?)*

```c
// type "func_t" is an address of a function with a int param and int return type
typedef int (*func_t)(int);
handle = dlopen("libmylib.so", RTLD_NOW); // open library
func_t f = dlsym(handle, "my_function"); // write my_function addr. into a func_t
int *i = dlsym(handle, "my_int"); // get address of "my_int"
(*f)(*i); // call "my_function" with "my_int" as parameter
```

`int dlclose (void * handle)`: schliesst das durch `handle` bezeichnete, zuvor geöffnete Objekt.

`char * dlerror()`: gibt Fehlermeldung als null-terminierten String zurück.

Konventionen: Shared Objects können ***automatisch*** bei Bedarf geladen werden. Der Linker verwendet den Linker-Namen, der Loader verwendet den SO-Namen.

- ***Linker-Name:*** `lib + Bibliotheksname + .so` *(z.B. libmylib.so)*,
- ***SO-Name:*** `Linker-Name + . + Versionsnummer` *(z.B. libmylib.so.2)*,
- ***Real-Name:*** `SO-name + . + Unterversionsnummer` *(z.B. libmylib.so.2.1)*

Shared Objects: Nahezu alle Executables benötigen ***zwei Shared Objects***: ***`libc.so`:*** Standard C library, ***`ld-linux.so`:*** ELF Shared Object loader *(Lädt Shared Objects und rekursiv alle Dependencies)*.

Implementierung dynamischer Bibliotheken: Müssen verschiebbar sein, mehrere müssen in den gleichen Prozess geladen werden. Die Aufgabe des Linkers wird in den Loader bzw. Dynamic Linker verschoben *(Load Time Relocation)*.

4.5. SHARED MEMORY

Dynamische Bibliotheken sollen ***Code zwischen Programmen teilen***. Code soll ***nicht mehrfach*** im Speicher abgelegt werden. Mit Shared Memory kann jedes Programm eine ***eigene virtuelle Page*** für den Code definieren. Diese werden auf denselben Frame im RAM gemappt. Benötigt ***Position-Independent Code*** *(Adressen nur relativ zum Instruction Pointer, Prozessor muss relative Instruktionen anbieten)*.

Relative Moves via Relative Calls: Mittels Hilfsfunktion wird Rücksprungadresse in Register abgelegt, somit kann relativ dazu gearbeitet werden.

Global Offset Table (GOT): Pro dynamische Bibliothek & Executable vorhanden, enthält pro Symbol einen Eintrag. Der Loader füllt zur Laufzeit die Adressen in die GOT ein.

Procedure Linkage Table (PLT): Implementiert Lazy Binding. Enthält pro Funktion einen Eintrag, dieser enthält Sprungbefehl an Adresse in GOT-Eintrag. Dieser zeigt auf eine Proxy-Funktion, welche den GOT-Eintrag überschreibt. ***Vorteil:*** erspart bedingten Sprung.

5. THREADS

Jeder ***Prozess*** hat virtuell den ***ganzen Rechner*** für ***sich alleine***. ***Prozesse*** sind gut geeignet für ***unabhängige Applikationen***. Nachteile: Realisierung ***paralleler Abläufe*** innerhalb derselben Applikation ist ***aufwändig***. ***Overhead*** zu gross falls nur kürzere Teilaktivitäten, ***gemeinsame Ressourcennutzung*** ist ***erschwert***.

Threads: ***parallel ablaufende Aktivitäten innerhalb eines Prozesses***, welche auf ***alle*** Ressourcen im Prozess gleichermassen Zugriff haben. Benötigen ***eigenen Kontext*** und ***eigenen Stack***. Informationen werden in einem ***Thread-Control-Block*** abgelegt.

5.1. AMDAHLS REGEL

Nur bestimmte Teile eines Algorithmus können parallelisiert werden.

- T Ausführungszeit, wenn ***komplett seriell*** durchgeführt *(Im Bild: $T = T_0 + T_1 + T_2 + T_3 + T_4$)*
- n Anzahl der Prozessoren
- T' Ausführungszeit, wenn ***maximal parallelisiert*** gesuchte Grösse
- T_s Ausführungszeit für den Anteil, der ***seriell*** ausgeführt werden ***muss*** *(Im Bild: $T_s = T_0 + T_2 + T_4$)*
- $T - T_s$ Ausführungszeit für den Anteil, der ***parallel*** ausgeführt werden ***kann*** *(Im Bild: $T_1 + T_3$)*
- $(T - T_s)/n$ Parallel-Anteil verteilt auf alle n Prozessoren. *(Im Bild: $(T_1 + T_3)/n$)*
- $T_s + \frac{T-T_s}{n}$ Serieller Teil + Paralleler Teil $= T'$

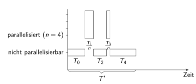

Die ***serielle Variante*** benötigt also höchstens ***f mal mehr Zeit*** als die ***parallele Variante***:

$$f \leq \frac{T}{T'} = \frac{T}{T_s + \frac{T-T_s}{n}}$$

f heisst auch ***Speedup-Faktor***, weil die parallele Variante max. f-mal schneller ist als die serielle.

Definiert man $s = T_s/T$, also den seriellen Anteil am Algorithmus, dann ist $s \cdot T = T_s$. Dadurch erhält man f unabhängig von der Zeit:

$$f \leq \frac{T}{T_s + \frac{T-T_s}{n}} = \frac{T}{s \cdot T + \frac{T - s \cdot T}{n}} = \frac{T}{s \cdot T + \frac{1-s}{n} \cdot T} \Rightarrow f \leq \frac{1}{s + \frac{1-s}{n}}$$

5.1.1. Bedeutung

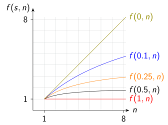

- Abschätzung einer ***oberen Schranke*** für den maximalen Geschwindigkeitsgewinn
- Nur wenn ***alles*** parallelisierbar ist, ist der Speedup ***proportional*** und ***maximal*** $f(0, n) = n$
- Sonst ist der Speedup mit ***höherer Prozessor-Anzahl*** immer ***geringer*** *(Kurve flacht ab)*
- $f(1, n)$: rein seriell

Grenzwert: Mit höherer Anzahl Prozessoren nähert sich der Speedup $1/s$ an:

$$\lim_{n\to\infty} \frac{1-s}{n} = 0 \qquad \lim_{n\to\infty} s + \frac{1-s}{n} = s \qquad \lim_{n\to\infty} \frac{1}{s + \frac{1-s}{n}} = \frac{1}{s}$$

5.2. POSIX THREAD API

```c
int pthread_create(
    pthread_t * thread_id, pthread_attr_t const *attributes,
    void * (*start_function) (void *), void *argument)
```

erzeugt einen Thread, die ID des neuen Threads wird im Out-Parameter `thread_id` zurückgegeben. ***`attributes`*** ist ein opakes Objekt, mit dem z.B. die Stack-Grösse spezifiziert werden kann. Die erste auszuführende Instruktion ist die Funktion in `start_function`. `argument` ist ein Pointer auf eine Datenstruktur auf dem Heap für die Argumente für `start_function`.

```c
// Erstellung
struct T { // params of function
  int value;
};
void * my_start (void * arg) {
  struct T * p = arg;
  printf ("%d\n", p->value);
  free (arg);
  return 0:
}
```

```c
// Verwendung
void start_my_thread (void) {
  struct T * t = malloc (sizeof (struct T));
  t->value = 109; // set argument
  pthread_t tid;
  pthread_create (
    &tid,
    0, // default attributes
    &my_start,
    t); }
```

Thread-Attribute:

```c
pthread_attr_t attr; // Variabel erstellen
pthread_attr_init (&attr); // Variabel initialisieren
pthread_attr_setstacksize (&attr, 1 << 16); // 64kb Stackgrösse
pthread_create (..., &attr, ...); // Thread erstellen
pthread_attr_destroy (&attr); // Attribute löschen
```

Lebensdauer: Lebt solange, bis er aus der Funktion ***`start_function`*** zurückspringt, er ***`pthread_exit`*** oder ein anderer Thread ***`pthread_cancel`*** aufruft oder sein Prozess beendet wird.

`void pthread_exit (void *return_value)`: ***Beendet*** den Thread und gibt den `return_value` zurück. Das ist äquivalent zum Rücksprung aus `start_function` mit dem Rückgabewert.

`int pthread_cancel (pthread_t thread_id)`: Sendet eine ***Anforderung***, dass der Thread mit `thread_id` ***beendet*** werden soll. Die Funktion ***wartet nicht***, dass der Thread ***tatsächlich beendet*** wurde. Der Rückgabewert ist 0, wenn der Thread existiert, bzw. `ESRCH` *(error_search)*, wenn nicht.

`int pthread_detach (pthread_t thread_id)`: ***Entfernt den Speicher***, den ein Thread belegt hat, falls dieser ***bereits beendet*** wurde. Beendet den Thread aber ***nicht***. *(Erstellt Daemon Thread)*

`int pthread_join (pthread_t thread_id, void **return_value)`: ***Wartet*** solange, bis der Thread mit `thread_id` ***beendet*** wurde. Nimmt den ***Rückgabewert*** des Threads im Out-Parameter ***`return_value`*** entgegen. Dieser kann ***`NULL`*** sein, wenn nicht gewünscht. Ruft ***`pthread_detach`*** auf.

`pthread_t pthread_self (void)`: Gibt die ***ID*** des ***gerade laufenden*** Threads zurück.

5.3. THREAD-LOCAL STORAGE (TLS)

TLS ist ein Mechanismus, der ***globale Variablen per Thread*** zur Verfügung stellt. Dies benötigt mehrere explizite Einzelschritte: **Bevor Threads erzeugt werden:** Anlegen eines ***Keys***, der die TLS-Variable ***identifiziert***, ***Speichern*** des Keys in einer ***globalen Variable*** **Im Thread:** ***Auslesen*** des Keys aus der globalen Variable, ***Auslesen / Schreiben*** des Werts anhand des Keys.

`int pthread_key_create(pthread_key_t *key, void (*destructor) (void*))`: Erzeugt einen ***neuen Key*** im Out-Parameter `key`. ***Opake Datenstruktur***. Am Thread-Ende Call auf `destructor`.

`int pthread_key_delete(pthread_key_t key)`: ***Entfernt den Key*** und die entsprechenden Values aus allen Threads. Der Key darf nach diesem Aufruf ***nicht mehr verwendet*** werden. Sollte erst aufgerufen werden, wenn alle dazugehörende Threads beendet sind.

`int pthread_setspecific(pthread_key_t key, const void * value)`

`void * pthread_getspecific(pthread_key_t key)` ***schreibt*** bzw. ***liest*** den Wert, der mit dem Key in diesem Thread assoziiert ist. Oft als ***Pointer auf einen Speicherbereich*** verwendet.

```c
// Setup
typedef struct {
  int code;
  char *message;
} error_t;
pthread_key_t error;
void set_up_error (void) {
  // am Anfang des Threads aufgerufen
  pthread_setspecific(
   error, malloc(sizeof(error_t)))}
```

```c
// Lesen und Schreiben im Thread
void print_error (void) {
  error_t * e =
pthread_getspecific(error);
  printf("Error %d: %s\n",
    e->code, e->message);}
int force_error (void) {
  error_t * e =
pthread_getspecific(error);
  e->code = 98;
  e->message = "file not found";
  return -1;}
```

```c
// Main und Thread
void *thread_function (void *) {
  set_up_error();
  if (force_error () == -1) { print_error (); }
}
int main (int argc, char **argv) {
  pthread_key_create (&error, NULL); // Key erzeugen
  pthread_t tid;
  pthread_create (&tid, NULL, &thread_function, NULL); // Threads erzeugen
  pthread_join (tid, NULL);
}
```

6. SCHEDULING

Auf einem Prozessor läuft zu einem Zeitpunkt immer ***höchstens ein Thread***. Es gibt folgende Zustände:

- ***Running*** *(der Thread, der gerade läuft)*
- ***Ready*** *(Threads die laufen können, es aber gerade nicht tun)*
- ***Waiting:*** *(Threads, die auf ein Ereignis warten, können nicht direkt in den Running State wechseln)*

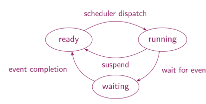

Übergänge von einem Status zum anderen werden ***immer vom OS*** vorgenommen. Dieser Teil vom OS heisst ***Scheduler***.

Das OS ***registriert Threads*** auf ein Ereignis und setzt sie in den Zustand «waiting». Tritt das Ereignis auf, ändert das OS den Zustand auf ***ready***. *(Es laufen nur Threads auf dem Prozessor, die nicht warten.)*

Ready-Queue: In der Ready-Queue *(kann auch ein Tree sein)* befinden sich alle Threads, die ***bereit sind zu laufen***.

Powerdown-Modus: Wenn kein Thread ***laufbereit*** ist, schaltet das OS den Prozessor in ***Standby*** und wird durch ***Interrupt*** wieder geweckt.

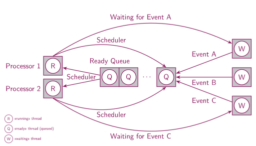

Arten von Threads: ***I/O-lastig*** *(Wenig rechnen, viel I/O-Geräte-Kommunikation)*, ***Prozessor-lastig*** *(Viel rechnen, wenig Kommunikation)*

Arten der Nebenläufigkeit: ***Kooperativ*** *(Threads entscheiden selbst über Abgabe des Prozessors)*, ***Präemptiv*** *(Scheduler entscheidet, wann einem Thread der Prozessor entzogen wird)*

Präemptives Multithreading: Thread läuft, bis er auf etwas zu ***warten*** beginnt, Prozessor ***yielded***, ein ***System-Timer-Interrupt*** auftritt oder ein ***bevorzugter Thread*** erzeugt oder ready wird.

Parallele, quasiparallele und nebenläufige Ausführung: ***Parallel*** *(Tatsächliche Gleichzeitigkeit, n Prozessoren für n Threads)*, ***Quasiparallel*** *(n Threads auf $< n$ Prozessoren abwechselnd)*, ***Nebenläufig*** *(Überbegriff für parallel oder quasiparallel)*

Bursts: ***Prozessor-Burst*** *(Thread belegt Prozessor voll)*, ***I/O-Burst*** *(Thread belegt Prozessor nicht)*. Jeder Thread kann als ***Abfolge*** von ***Prozessor-Bursts*** und ***I/O-Bursts*** betrachtet werden.

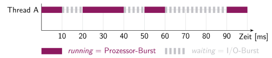

6.1. SCHEDULING-STRATEGIEN

Anforderungen an einen Scheduler können vielfältig sein. ***Geschlossene Systeme*** *(Hersteller kennt Anwendungen und ihre Beziehungen)* vs. ***Offene Systeme*** *(Hersteller muss von typischen Anwendungen ausgehen)*

Anwendungssicht, Minimierung von: ***Durchlaufzeit*** *(Zeit vom Starten des Threads bis zu seinem Ende)*, ***Antwortzeit*** *(Zeit vom Empfang eines Requests bis die Antwort zur Verfügung steht)*, ***Wartezeit*** *(Zeit, die ein Thread in der Ready-Queue verbringt)*.

Aus Systemsicht, Maximierung von: ***Durchsatz*** *(Anzahl Threads, die pro Intervall bearbeitet werden)*, ***Prozessor-Verwendung*** *(Prozentsatz der Verwendung des Prozessors gegenüber der Nichtverwendung)*

Latenz ist die durchschnittliche Zeit zwischen Auftreten und Verarbeiten eines Ereignisses. Im schlimmsten Fall tritt das Ereignis dann auf, wenn der Thread gerade vom Prozessor entfernt wurde. Um die Antwortzeit zu verringern, muss jeder Thread öfters ausgeführt werden, was jedoch zu mehr Thread-Wechsel und somit zu mehr Overhead führt. ***Die Utilization nimmt also ab, wenn die Antwortzeit verringert wird.***

Idealfall: Parallele Ausführung *(Dient als idealisierte Schranke, besser geht nicht)*

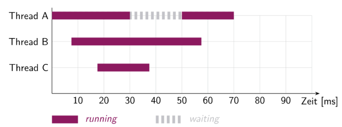

FCFS-Strategie *(First Come, First Served)*

Nicht präemptiv: Threads geben den Prozessor nur ab, wenn sie auf «waiting» wechseln oder sich beenden.

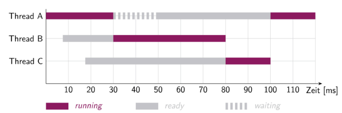

SJF-Strategie *(Shortest Job First)*

Scheduler wählt den Thread aus, der den ***kürzesten*** Prozessor-Burst hat. Bei gleicher Länge wird nach FCFS ausgewählt. Kann ***kooperativ*** oder ***präemptiv*** sein. Ergibt ***optimale Wartezeit***, kann jedoch nur ***korrekt implementiert*** werden, wenn die Länge der Bursts ***bekannt*** sind.

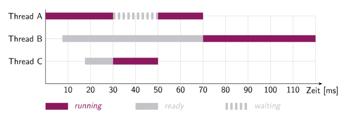

Round-Robin: ***Zeitscheibe*** von etwa 10 bis 100ms. ***FCFS***, aber ein Thread kann nur solange laufen, bis seine ***Zeitscheibe erschöpft*** ist, dann wird der in der ***Queue hinten angehängt***.

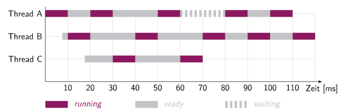

Prioritäten-basiert: Jeder Thread erhält ***eine Nummer***, seine ***Priorität***. Threads mit höherer Priorität werden vor Threads mit niedriger Priorität ausgewählt. Threads mit gleicher Priorität werden nach FCFS ausgewählt. Prioritäten je nach OS unterschiedlich.

Starvation: Thread mit niedriger Priorität wird immer ***übergangen*** und kann nie laufen. Abhilfe z.B. mit ***Aging:*** in bestimmten Abständen wird die Priorität um 1 erhöht.

Multi-Level Scheduling: Threads werden in ***Level*** aufgeteilt *(Priorität, Prozesstyp, Hinter-/Vordergrund)*, jedes Level hat eigene Ready-Queue und kann individuell gescheduled werden. *(zB. Timeslice/Queue)*

Multi-Level Scheduling mit Feedback: Erschöpft ein Thread seine Zeitscheibe, wird seine Priorität um 1 verringert. Typischerweise werden die Zeitscheiben mit ***niedrigerer Priorität grösser*** und Threads mit ***kurzen Prozessor-Bursts bevorzugt***. Threads in tiefen Queues dürfen zum Ausgleich länger am Stück laufen.

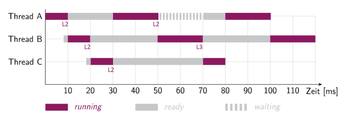

6.2. PRIORITÄTEN IN POSIX

Nice-Wert: Jeder Prozess hat einen Nice-Wert von -20 *(soll bevorzugt werden)* bis $+19$ *(nicht bevorzugt)*

`nice [-n increment] utility [argument...]`: Nice-Wert beim Start erhöhen oder verringern

`int nice (int i)`: Nice-Wert im Prozess erhöhen oder verringern. *(Addiert i zum Wert dazu.)*

`int getpriority (int which, id_t who)`: gibt den Nice-Wert von p zurück

`int setpriority (int which, id_t who, int prio)`: setzt den Nice-Wert.

- ***`which`:*** `PRIO_PROCESS`, `PRIO_PGRP` oder `PRIO_USER`
- ***`who`:*** ID des Prozesses, der Gruppe oder des Users

Priorität bei Thread-Erzeugung setzen

Funktionen ohne `attr` bevor Thread gestartet wird:

- `int pthread_getschedparam(pthread_t thread, int * policy, struct sched_param * param)`
- `int pthread_setschedparam(pthread_t thread, int policy, const struct sched_param * param)`

```c
pthread_attr_t a; pthread_attr_init (&a); // initialize attributes
struct sched_param p;
pthread_attr_getschedparam ( &a, &p ); // read parameter
// set p.sched_priority here... (code cut for brevity)
pthread_attr_setschedparam ( &a, &p ); // write modified parameters
pthread_create ( &id, &a, thread_function, argument );
pthread_attr_destroy ( &a ); // destroy attributes
```

7. MUTEXE UND SEMAPHORE

Jeder Thread hat seinen ***eigenen*** Instruction-Pointer und Stack-Pointer. Wenn Ergebnisse von der ***Ausführungsreihenfolge*** einzelner Instruktionen abhängen, spricht man von einer ***Race Condition***. Threads müssen ***synchronisiert*** werden, damit keine ***Race Condition*** entsteht.
Critical Section: Code-Bereich, in dem Daten mit anderen Threads ***geteilt*** werden. Muss unbedingt synchronisiert werden.
Atomare Instruktionen: Eine atomare Instruktion kann vom Prozessor ***unterbrechungsfrei*** ausgeführt werden. *(**Achtung:** Selbst einzelne Assembly-Instruktionen nicht immer atomar!)*
Anforderungen an Synchronisations-Mechanismen: ***Gegenseitiger Ausschluss*** *(Nur ein Thread darf in Critical Section sein)*, ***Fortschritt*** *(Entscheidung, wer in die Critical Section darf, muss in endlicher Zeit getroffen werden)*, ***Begrenztes Warten*** *(Thread wird nur n mal übergangen, bevor er in die Critical Section darf)*.
Implementierung: Nur ***mit HW-Unterstützung*** möglich. Es gibt zwei atomare Instruktionen: ***Test-And-Set*** *(Setzt einen `int` auf 1 und returnt den vorherigen Wert: `test_and_set(int * target) {int value = *target; *target = 1; return value;}`)* und ***Compare-and-Swap*** *(Überschreibt einen `int` mit einem spezifizierten Wert, wenn dieser dem erwarteten Wert entspricht: `compare_and_swap (int *a, int expected, int new_a) { int value = *a; if (value == expected) { *a = new_a; } return value; }`)*.

7.1. SEMAPHORE

Enthält Zähler $z \geq 0$. Wird nur über `Post(v)` *(Erhöht z um 1)* und `Wait(v)` zugegriffen.
(Wenn $z > 0$, verringert z um 1 und fährt fort. Wenn $z = 0$, setzt den Thread in waiting, bis anderer Thread z erhöht).

`int sem_init (sem_t *sem, int pshared, unsigned int value)`: ***Initialisiert*** den Semaphor, typischerweise als ***globale Variable***. `pshared = 1`: Verwendung über mehrere Prozesse.
`sem_t sem; int main ( int argc, char ** argv ) { sem_init (&sem, 0, 4); }` oder als Parameter für den Thread *(Speicher auf dem Stack oder Heap)*: `struct T { sem_t *sem; ... };`

`int sem_wait (sem_t *sem); int sem_post (sem_t *sem)`: implementieren ***Post*** und ***Wait***.
`int sem_trywait (sem_t *sem); int sem_timedwait (sem_t *sem, const struct timespec *abs_timeout)`: Sind wie `sem_wait`, aber ***brechen ab***, falls Dekrementierung ***nicht*** durchgeführt werden kann. `sem_trywait` bricht sofort ab, `sem_timedwait` nach der angegebenen Zeitdauer.
`int sem_destroy (sem_t *sem)`: ***Entfernt Speicher***, den das OS mit `sem` ***assoziiert*** hat.

```c
semaphore free = n; semaphore used = 0;

// Producer                                   // Consumer
while (1) {                                   while (1) {
  // Warte, falls Customer zu langsam           // Warte, falls Producer zu langsam
  WAIT (free); // Hat es Platz in Queue?        WAIT (used); // Hat es Elem. in Queue?
  produce_item (&buffer[w], ...);               consume (&buffer[r]);
  POST (used); // 1 Element mehr in Queue       POST (free); // 1 Element weniger in Q
  w = (w+1) % BUFFER_SIZE;                      r = (r+1) % BUFFER_SIZE;
}                                             }
```

7.2. MUTEXE

Ein Mutex hat einen ***binären Zustand z***, der nur durch zwei Funktionen verändert werden kann: ***Acquire*** *(Wenn $z = 0$, setze z auf 1 und fahre fort. Wenn $z = 1$, blockiere den Thread, bis $z = 0$)*, ***Release*** *(Setzt $z = 0$)*. Auch als non-blocking-Funktion: `int pthread_mutex_trylock (pthread_mutex_t *mutex)`

```c
// Beispiel Initialisierung                 // Beispiel Verwendung in Threads
pthread_mutex_t mutex; // global variable void * thread_function (void * args) {
int main() {                                 while (running) { ...
  pthread_mutex_init (&mutex, 0);              // Enter critical section:
  // run threads & wait for them to finish     pthread_mutex_lock (&mutex);
  pthread_mutex_destroy (&mutex); }            // Leave critical section:
                                               pthread_mutex_unlock (&mutex);...}}
```

Priority Inversion: Ein ***hoch-priorisierter*** Thread C wartet auf eine Ressource, die von einem ***niedriger priorisierten*** Thread A ***gehalten*** wird. Ein Thread mit Priorität zwischen diesen beiden Threads erhält den Prozessor. Kann mit **Priority Inheritance** gelöst werden: Die Priorität von A wird temporär auf die Priorität von C gesetzt, damit der Mutex schnell wieder freigegeben wird.

8. SIGNALE, PIPES UND SOCKETS

8.1. SIGNALE

Signale ermöglichen es, einen Prozess ***von aussen*** zu unterbrechen, wie ein ***Interrupt***. ***Unterbrechen*** des gerade laufenden Prozesses/Threads, Auswahl und Ausführen der ***Signal-Handler-Funktionen***, ***Fortsetzen*** des Prozesses. Werden über ungültige Instruktionen oder Abbruch auf Seitens Benutzer ausgelöst. Jeder Prozess hat pro Signal einen Handler.
Handler: ***Ignore-Handler*** *(ignoriert das Signal)*, ***Terminate-Handler*** *(beendet das Programm)*, ***Abnormal-Terminate-Handler*** *(beendet Programm und erzeugt Core-Dump)*. Fast alle Signale ausser `SIGKILL` und `SIGSTOP` können ***überschrieben*** werden.
Programmfehler-Signale: `SIGFPE` *(Fehler in arithmetischen Operation)*, `SIGILL` *(Ungültige Instruktion)*, `SIGSEGV` *(Ungültiger Speicherzugriff)*, `SIGSYS` *(Ungültiger Systemaufruf)*
Prozesse abbrechen: `SIGTERM` *(Normale Anfrage an den Prozess, sich zu beenden)*, `SIGINT` *(Nachdrücklichere Aufforderung an den Prozess, sich zu beenden)*, `SIGQUIT` *(Wie `SIGINT`, aber anormale Terminierung)*, `SIGABRT` *(Wie `SIGQUIT`, aber vom Prozess an sich selber)*, `SIGKILL` *(Prozess wird «abgewürgt», kann nicht verhindert werden)*
Stop and Continue: `SIGTSTP` *(Versetzt den Prozess in den Zustand stopped, ähnlich wie waiting)*, `SIGSTOP` *(Wie `SIGTSTP`, aber kann nicht ignoriert oder abgefangen werden)*, `SIGCONT` *(Setzt den Prozess fort)*
Signale von der Shell senden: `kill 1234 5678` sendet `SIGTERM` an Prozesse 1234 und 5678
`int sigaction (int signal, struct sigaction *new, struct sigaction *old)`: Definiert Signal-Handler für `signal`, wenn `new` $\neq 0$. *(Eigene Signal-Handler definiert via `sigaction` struct: `sa_handler`: Zu callende Funktion, `sa_mask`: Blockierte Signale während Ausführung, bearbeitet nur durch `sig*set()`-Funktionen: `sigemptyset`, `sigfillset`, `sigaddset`, `sigdelset`, `sigismember`)*

8.2. PIPES

Eine geöffnete Datei entspricht einem ***Eintrag in der File-Descriptor-Tabelle (FDT)*** im Prozess. Zugriff über ***File-API*** *(`open`, `close`, `read`, `write`, …)*. Das OS speichert ***je Eintrag der Prozess-FDT*** einen ***Verweis auf die globale FDT***. Bei `fork()` wird die FDT auch kopiert.
`int dup (int source_fd); int dup2 (int source_fd, int destination_fd)`: ***Duplizieren*** den File-Descriptor `source_fd`. `dup` alloziert einen neuen FD, `dup2` überschreibt `destination_fd`.

8.2.1. Umleiten des Ausgabestreams

```c
int fd = open("log.txt", ...);
int id = fork();
if (id == 0) { // child process
  dup2(fd, 1); // duplicate fd for log.txt as standard output
               // e.g. load new image with exec*, fd's remain
} else { /* parent process */ close (fd); }
```

Eine **Pipe** ist eine «Datei» *(Eine Datei muss nur `open`, `close` etc. unterstützen)* im Hauptspeicher, die über zwei File-Deskriptoren verwendet wird: ***read end*** und ***write end***. Daten, die in ***write end*** geschrieben werden, können aus ***read end*** genau ***einmal*** und als ***FIFO*** gelesen werden. Pipes erlauben ***Kommunikation über Prozess-Grenzen hinweg***. Ist unidirektional.

```c
int fd[2]; // 0 = read, 1 = write
pipe (fd);
int id = fork();
```

```c
if (id == 0) { // Child thread
  close (fd [1]); // don't use write end
  char buffer [BSIZE];
  int n = read (fd[0], buffer, BSIZE);
} else { // Parent thread
  close (fd[0]); // don't use read end
  char * text = "I <3 segfaults";
  write (fd[1], text, strlen(text) + 1);
}
```

Pipe lebt nur so lange, wie mind. ein Ende geöffnet ist. Alle Read-Ends geschlossen → `SIGPIPE` an Write-End. Mehrere Writes können zusammengefasst werden. Lesen mehrere Prozesse dieselbe Pipe, ist unklar, wer die Daten erhält.

`int mkfifo (const char *path, mode_t mode)`: Erzeugt eine Pipe ***mit Namen und Pfad*** im Dateisystem. Hat via `mode` Permission Bits wie normale Datei. Lebt unabhängig vom erzeugenden Prozess, je nach System auch über Reboots hinweg. Muss explizit mit `unlink` gelöscht werden.

8.3. SOCKETS

Ein Socket ***repräsentiert einen Endpunkt auf einer Maschine***. Kommunikation findet im Regelfall zwischen zwei Sockets statt *(UDP, TCP über IP sowie Unix-Domain-Sockets)*. Sockets benötigen für Kommunikation einen Namen *(Beispiel IP: IP-Adresse & Portnummer)*.
`int socket(int domain, int type, int protocol)`: ***Erzeugt*** einen neuen Socket als «Datei». Socket sind nach Erzeugung zunächst ***unbenannt***. Alle Operationen blockieren per default.
`Domain` *(AF_UNIX, AF_INET)*, `type` *(SOCK_DGRAM, SOCK_STREAM)*, `protocol` *(System-spezifisch, 0 = Default-Protocol)*
Client: `connect` *(Verbindung unter Angabe einer Adresse aufbauen)*, `send / write` *(Senden von Daten, $0 - \infty$ mal)*, `recv / read` *(Empfangen von Daten, $0 - \infty$ mal)*, `close` *(Schliessen der Verbindung)*
Server: `bind` *(Festlegen einer nach aussen sichtbaren Adresse)*, `listen` *(Bereitstellen einer Queue zum Sammeln von Verbindungsanfragen von Clients)*, `accept` *(Erzeugen einer Verbindung auf Anfrage von Client)*, `recv / read` *(Empfangen von Daten, $0 - \infty$ mal)*, `send / write` *(Senden von Daten, $0 - \infty$ mal)*, `close` *(Schliessen der Verbindung)*

```c
struct sockaddr_in ip_addr;
ip_addr.sin_port = htons (443); // default HTTPS port
inet_pton (AF_INET, "192.168.0.1", &ip_addr.sin_addr.s_addr);
// IP address in memory: 0xC0 0xA8 0x00 0x01
// Port in memory: 0x01 0xBB
```

`htons()` konvertiert 16 Bit von Host-Byte-order *(LE)* zu Network-Byte-Order *(BE)*, `htonl()` 32 Bit. `ntohs()` und `ntohl()` sind Gegenstücke. `inet_pton()` konvertiert protokoll-spezifische Adresse von String zu Network-BO. `inet_ntop()` ist das Gegenstück *(network-to-presentation)*.
`int bind (int socket, const struct sockaddr *local_address, socklen_t addr_len)`: ***Bindet*** den Socket an die angegebene, unbenutzte lokale Adresse, wenn noch nicht gebunden. Blockiert, bis der Vorgang abgeschlossen ist.
`int connect (int socket, const struct sockaddr *remote_addr, socklen_t addr_len)`: ***Aufbau*** einer Verbindung. Bindet den Socket an eine neue, unbenutzte lokale Adresse, wenn noch nicht gebunden. Blockiert, bis Verbindung steht oder ein Timeout eintritt.
`int listen (int socket, int backlog)`: ***Markiert*** den Socket als «bereit zum Empfang von Verbindungen». Erzeugt eine Warteschlange, die so viele Verbindungsanfragen aufnehmen kann, wie `backlog` angibt.
`int accept (int socket, struct sockaddr *remote_address, socklen_t address_len)`: ***Wartet***, bis Verbindungsanfrage in der Warteschlange eintrifft. Erzeugt einen neuen Socket und bindet ihn an eine neue lokale Adresse. Die Adresse des Clients wird in `remote_address` geschrieben. Der neue Socket kann keine weiteren Verbindungen annehmen, der bestehende schon.

8.3.1. Typisches Muster für Server

```c
int server_fd = socket ( ... ); bind (server_fd, ...); listen (server_fd, ...);
while (running) {
  int client_fd = accept (server_fd, 0, 0);
  delegate_to_worker_thread (client_fd); // will call close(client_fd)
}
```

`send (fd, buf, len, 0) == write (fd, buf, len); recv (fd, buf, len, 0) == read (fd, buf, len)`: ***Senden und Empfangen von Daten***. Erweitern `read()` bzw. `write()` um Socket-Funktionalitäten durch den `flags`-Parameter. Puffern der Daten ist Aufgabe des Netzwerkstacks.
`int close (int socket)`: ***Schliesst*** den Socket für den aufrufenden Prozess. Hat ein anderer Prozess den Socket noch geöffnet, bleibt die Verbindung bestehen. Die Gegenseite wird nicht benachrichtigt.
`int shutdown (int socket, int mode)`: ***Schliesst*** den Socket für alle Prozesse und baut die entsprechende Verbindung ab. `mode`: `SHUT_RD` *(Keine Lese-Zugriffe mehr)*, `SHUT_WR` *(Keine Schreib-Zugriffe mehr)*, `SHUT_RDWR` *(Keine Lese- oder Schreib-Zugriffe mehr)*

9. MESSAGE PASSING UND SHARED MEMORY

Prozesse sind voneinander isoliert, müssen jedoch trotzdem miteinander interagieren. ***Message-Passing*** ist ein Mechanismus mit zwei Operationen: ***Send*** *(Kopiert die Nachricht **aus** dem Prozess: `send (message)`)*, ***Receive:*** *(Kopiert die Nachricht **in** den Prozess: `receive (message)`)*. Dabei können Implementierungen nach verschiedenen Kriterien unterschieden werden *(Feste oder Variable Nachrichtengrösse, direkte oder indirekte / synchrone oder asynchrone Kommunikation, Pufferung, mit oder ohne Prioritäten für Nachrichten)*.
Feste oder variable Nachrichtengrösse: feste Nachrichtengrösse ist einfacher zu implementieren, aber umständlicher zu verwenden als variable Nachrichtengrösse.
Direkte Kommunikation: Kommunikation nur zwischen genau zwei Prozessen, Sender muss Empfänger kennen. Es gibt ***symmetrische direkte Kommunikation*** *(Empfänger muss Sender auch kennen)* und ***asymmetrische direkte Kommunikation*** *(Empfänger muss Sender nicht kennen)*.
Indirekte Kommunikation: Prozess sendet Nachricht an ***Mailboxen, Ports oder Queues***. Empfänger empfängt aus diesem Objekt. Beide Teilnehmer müssen die gleiche(n) Mailbox(en) kennen.
Lebenszyklus Queue: Wenn diese Queue einem Prozess gehört, lebt sie solange wie der Prozess. Wenn sie dem OS gehört, muss das OS das Löschen übernehmen.
Synchronisation: ***Blockierendes Senden*** *(Sender wird solange blockiert, bis die Nachricht vom Empfänger empfangen wurde)*, ***Nicht-blockierendes Senden*** *(Sender sendet Nachricht und fährt sofort weiter)*, ***Blockierendes Empfangen*** *(Empfänger wird blockiert, bis Nachricht verfügbar)*, ***Nicht-blockierendes Empfangen*** *(Empfänger erhält Nachricht, wenn verfügbar, oder 0)*
Rendezvous: Sind Empfang und Versand ***beide blockierend***, kommt es zum Rendezvous, sobald beide Seiten ihren Aufruf getätigt haben. ***Impliziter Synchronisationsmechanismus***.

```c
// Producer                               // Consumer
message msg;                              message msg;
open(Q);                                  open(Q);
while(1) {                                while(1) {
  produce_next(&msg);                       receive(Q, &msg); // blocked until rec.
  send(Q, &msg); // blocked until sent      consume_next(&msg);
}                                         }
```

Pufferung: ***Keine*** *(Queue-Länge ist 0, Sender muss blockieren)*, ***Beschränkte*** *(Maximal n Nachrichten, Sender blockiert, wenn Queue voll ist.)*, ***Unbeschränkte*** *(Beliebig viele Nachrichten, Sender blockiert nie)*.
Prioritäten: In manchen Systemen können Nachrichten mit ***Prioritäten*** versehen werden. Der Empfänger holt die Nachricht mit der ***höchsten Priorität zuerst*** aus der Queue.

9.0.1. POSIX Message-Passing

OS-Message-Queues mit ***variabler Länge***, haben mindestens 32 Prioritäten und können ***synchron oder asynchron*** verwendet werden.
`mqd_t mq_open (const char *name, int flags, mode_t mode, struct mq_attr *attr)`: ***Öffnet*** eine Message-Queue mit systemweitem `name`, returnt Message-Queue-Descriptor. *(`name` muss mit «/» beginnen, `flags` & `mode` wie bei Dateien, `mq_attr`: Diverse Konfigurationen & Queue-Status, lesen und schreiben der Attribute mit `mp_getattr()`/`mq_setattr()`)*
`int mq_close (mqd_t queue)`: ***Schliesst*** die Queue mit dem Descriptor `queue` für diesen Prozess.
`int mq_unlink (const char *name)`: ***Entfernt*** die Queue mit dem Namen `name` aus dem System. ***Name*** wird ***sofort entfernt*** und Queue kann anschliessend ***nicht mehr geöffnet*** werden.
`int mq_send (mqd_t queue, const char *msg, size_t length, unsigned int priority)`: ***Sendet*** die Nachricht, die an Adresse `msg` beginnt und `length` Bytes lang ist, in die `queue`.
`int mq_receive (mqd_t queue, const char *msg, size_t length, unsigned int *priority)`: ***Kopiert*** die nächste Nachricht aus der Queue in den Puffer, der an Adresse `msg` beginnt und `length` Bytes lang ist. ***Blockiert***, wenn die Queue ***leer*** ist.

9.1. SHARED MEMORY

Frames des Hauptspeichers werden ***zwei (oder mehr) Prozessen*** P_1 und P_2 ***zugänglich*** gemacht. In P_1 wird Page V_1 auf einen Frame F abgebildet. In P_2 wird Page V_2 auf ***denselben*** Frame F abgebildet. Beide Prozesse können ***beliebig*** auf dieselben Daten zugreifen. Im Shared Memory müssen ***relative Adressen*** verwendet werden.

9.1.1. POSIX API

Das OS benötigt eine «Datei» S, das Informationen über den gemeinsamen Speicher verwaltet und eine ***Mapping Table*** je Prozess.

`int fd = shm_open ("/mysharedmemory", O_RDWR | O_CREAT, S_IRUSR | S_IWUSR)`: Erzeugt (falls nötig) und öffnet Shared Memory `/mysharedmemory` zum Lesen und Schreiben.
`int ftruncate (int fd, offset_t length)`: ***Setzt*** Grösse der «Datei». Muss ***zwingend*** nach Shared-Memory-Erstellung gesetzt werden, um entsprechend viele Frames zu allozieren. Wird für Shared Memory mit ganzzahligen Vielfachen der Page-/Framegrösse verwendet.
`int close (int fd)`: ***Schliesst*** «Datei». Shared Memory ***bleibt aber im System***.
`int shm_unlink (const char * name)`: ***Löscht*** das Shared Memory mit dem `name`. *(bleibt vorhanden, solange noch von Prozess geöffnet)*
`int munmap (void *address, size_t length)`: ***Entfernt*** das Mapping.

```c
void * address = mmap( // maps shared memory into virt. address space of process
  0,                      // void *hint_address (0 because nobody cares)
  size_of_shared_memory,  // size_t length (same length as used in ftruncate)
  PROT_READ | PROT_WRITE, // int protection (never use execute!)
  MAP_SHARED,             // int flags
  fd,                     // int file_descriptor
  0                       // off_t offset (start map from first byte)
);
```

9.2. VERGLEICH MESSAGE-PASSING UND SHARED MEMORY

Shared Memory ist schneller zu realisieren, aber schwer wartbar. ***Message-Passing*** erfordert mehr Engineering-Aufwand, schlussendlich aber in Mehr-Prozessor-Systemen bald performanter.

9.3. VERGLEICH MESSAGE-QUEUES UND PIPES

Message-Queues	*Pipes*
– bidirektional – Daten sind in einzelnen Messages organisiert – beliebiger Zugriff – Haben immer einen Namen	– unidirektional – übermittelt Bytestrom an Daten – FIFO-Zugriff – Müssen keinen Namen haben

10. UNICODE

10.1. ASCII - AMERICAN STANDARD CODE FOR INFORMATION INTERCHANGE

Hat ***128 definierte Zeichen***, ist also 7 Bit gross *(erste Hexzahl = Zeile, zweite Hexzahl = Spalte, d.h. 41_h = A)*.

	0	1	2	3	4	5	6	7	8	9	A	B	C	D	E	F
0	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	TAB	LF	VT	FF	CR	SO	SI
1	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SB	ESC	FS	GS	RS	US
2	␣	!	"	#	$	%	&	'	(	)	*	+	,	-	.	/
3	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5	P	Q	R	S	T	U	V	W	X	Y	Z	[	\	]	^	_
6	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7	p	q	r	s	t	u	v	w	x	y	z	{	|	}	~	DEL

Codepages: unabhängige Erweiterungen auf 8 Bit *(z.B. für andere Sprachen)*. Jede ist unterschiedlich und nicht direkt erkennbar.
Unicode: Hat zum Ziel, einen eindeutigen Code für ***jedes vorhandene Zeichen*** zu definieren. Der Bereich von $D8\,00_h$ bis $DF\,FF_h$ enthält aufgrund von UTF-16 keine gültigen Code-Points. Benötigt maximal 21 Bits, um alle Zeichen darstellen zu können.
Code-Points (CP): Nummer eines Zeichen – «welches Zeichen ist es?»
Code-Unit (CU): Einheit, um Zeichen in einem Encoding darzustellen *(bietet den Speicherplatz)*
P_i = i-tes Bit des unkodierten CPs, U_i = i-tes Code-Unit des kodierten CPs, B_i = i-tes Byte des kodierten CPs

10.2. UTF-32

Jede CU umfasst ***32 Bit***, jeder CP kann mit ***einer CU*** dargestellt werden. Direkte Kopie der Bits in die CU bei Big Endian, bei Little Endian werden P_0 bis P_7 in B_3 kopiert usw. Wird häufig intern in Programmen verwendet. Wurde aufgrund Memory Alignment auf 32 Bits erweitert, obwohl 24 Bits genügen würden *(Bessere Performance)*. Obere 11 Bits werden oft «zweckentfremdet».

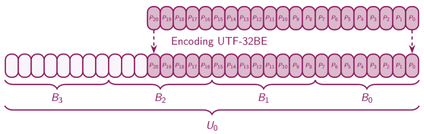

10.3. UTF-16

Jede CU umfasst ***16 Bit***, ein CP benötigt ***1 oder 2 CUs***. Encoding muss Endianness berücksichtigen. Die 2 CUs werden ***Surrogate Pair*** genannt, U_0: high surrogate, U_1: low surrogate. Bei ***2 Bytes*** *(1 CU)* wird direkt gemappt und vorne mit Nullen aufgefüllt. Bei ***4 Bytes*** sind $D8\,00_h$ bis $DF\,FF_h$ *(Bits 17-21)* wegen dem Separator ***ungültig*** und müssen «umgerechnet» werden.

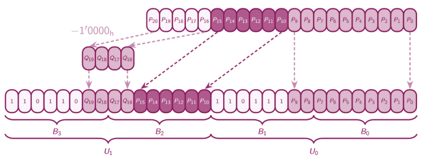

Beispiel
Encoding von U+10'437 (𐐷) $00\,0100\,0001\ 00\,0011\,0111_b$:

1. Code-Point P minus $1\,00\,00_h$ rechnen und in Binär umwandeln
   $P = 1\,04\,37_h, \quad Q = 1\,04\,37_h - 1\,00\,00_h = 04\,37_h = 00\,0000\,0001\ 00\,0011\,0111_b$
2. Obere & untere 10 Bits in Hex umwandeln
   $00\,01\ \ 00\,37_h$
3. Oberer Wert mit $D8\,00_h$ und unterer Wert mit $DC\,00_h$ addieren, um Code-Units zu erhalten
   $U_1 = 00\,01_h + D8\,00_h = D8\,01_h, \quad U_2 = 00\,37_h + DC\,00_h = DC\,37_h$
4. Zu BE/LE zusammensetzen
   $BE = \underline{D8\,01\,DC\,37_h}, \quad LE = \underline{01\,D8\,37\,DC_h}$

10.4. UTF-8

Jede CU umfasst ***8 Bit***, ein CP benötigt ***1 bis 4 CUs***. Encoding muss Endianness ***nicht*** berücksichtigen. Standard für Webpages. Echte Erweiterung von ASCII.

Code-Point in	U_3	U_2	U_1	U_0	*signifikant*
0_h - $7F_h$				$0xxx\,xxxx_b$	7 bits
80_h - $7\,FF_h$			$110x\,xxxx_b$	$10xx\,xxxx_b$	11 bits
$8\,00_h$ - $FF\,FF_h$		$1110\,xxxx_b$	$10xx\,xxxx_b$	$10xx\,xxxx_b$	16 bits
$1\,00\,00_h$ - $10\,FF\,FF_h$	$1111\,0xxx_b$	$10xx\,xxxx_b$	$10xx\,xxxx_b$	$10xx\,xxxx_b$	21 bits

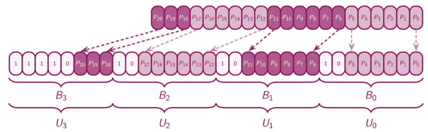

Beispiele
- ***ä***: $P = E4_h = 0\,0011\ 10\,0110_b$
  $\Rightarrow P_{10}...P_6 = 0\,0011_b = 03_h, \quad P_5...P_0 = 10\,0100_b = 24_h$
  $\Rightarrow U_1 = C0_h\ (= 1100\,0000_b) + 03_h = C3_h, \quad U_0 = 80_h\ (= 1000\,0000_b) + 24_h = A4_h$
  $\Rightarrow$ ä $= \underline{C3\,A4_h}$
- ***ặ***: $P = 1E\,B7_h = 0001\ 11\ 1010\ 11\ 0111_b$
  $\Rightarrow P_{15}...P_{12} = 01_h, \quad P_{11}...P_6 = 3A_h, \quad P_5...P_0 = 37_h$
  $\Rightarrow U_2 = E0_h\ (= 1110\,0000_b) + 01_h = E1_h, \quad U_1 = 80_h + 3A_h = BA_h, \ U_0 = 80_h + 37_h = B7_h$
  $\Rightarrow$ ặ $= \underline{E1\,BA\,B7_h}$

10.5. ENCODING-BEISPIELE

Zeichen	*Code-Point*	*UTF-32BE*	*UTF-32LE*	*UTF-8*	*UTF-16BE*	*UTF-16LE*
A	41_h	$00\,00\,00\,41_h$	$41\,00\,00\,00_h$	41_h	$00\,41_h$	$41\,00_h$
ä	$E4_h$	$00\,00\,00\,E4_h$	$E4\,00\,00\,00_h$	$C3\,A4_h$	$00\,E4_h$	$E4\,00_h$
α	$3\,B1_h$	$00\,00\,03\,B1_h$	$B1\,03\,00\,00_h$	$CE\,B1_h$	$03\,B1_h$	$B1\,03_h$
ặ	$1E\,B7_h$	$00\,00\,1E\,B7_h$	$B7\,1E\,00\,00_h$	$E1\,BA\,B7_h$	$1E\,B7_h$	$B7\,1E_h$
𐌰	$1\,03\,30_h$	$00\,01\,03\,30_h$	$30\,03\,01\,00_h$	$F0\,90\,8C\,B0_h$	$D8\,00\,DF\,30_h$	$00\,D8\,30\,DF_h$

*Bei LE / BE werden nur die Zeichen **innerhalb** eines Code-Points vertauscht, nicht die Code-Points an sich.*

11. EXT2-DATEISYSTEM

Partition *(Ein Teil eines Datenträgers, wird selbst wie ein Datenträger behandelt.)*, ***Volume*** *(Ein Datenträger oder eine Partition davon.)*, ***Sektor*** *(Kleinste logische Untereinheit eines Volumes. Daten werden als Sektoren transferiert. Grösse ist von HW definiert. Enthält Header, Daten und Error-Correction-Codes.)*, ***Format*** *(Layout der logischen Strukturen auf dem Datenträger, wird vom Dateisystem definiert.)*

11.1. BLOCK

Ein Block besteht aus ***mehreren aufeinanderfolgenden Sektoren*** *(1 KB, 2 KB oder 4 KB (normal))*. Das gesamte Volume ist in ***Blöcke aufgeteilt*** und Speicher wird ***nur in Form von Blöcken*** alloziert. Ein Block enthält nur Daten einer ***einzigen Datei***. Es gibt ***Logische Blocknummern*** *(Blocknummer vom Anfang der Datei aus gesehen, wenn Datei eine ununterbrochene Abfolge von Blöcken wäre)* und ***Physische Blocknummern*** *(Tatsächliche Blocknummer auf dem Volume)*.

11.2. INODES

Enthält ***alle Metadaten*** über die Datei, ***ausser Namen oder Pfad*** *(Grösse, Anzahl der verwendeten Blöcke, Erzeugungszeit, Zugriffszeit, Modifikationszeit, Löschzeit, Owner-ID, Group-ID, Flags, Permission Bits)*. Hat eine ***fixe Grösse*** je Volume: Zweierpotenz, mind. 128 Byte, max. 1 Block. Der Inode ***verweist auf die Blöcke***, die ***Daten für eine Datei*** enthalten. Enthält ein Array `i_block` mit 15 Einträgen zu je 32 Bit.

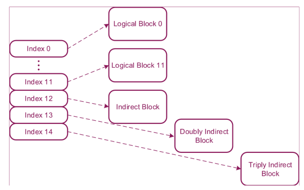

Lokalisierung: Alle Inodes aller Blockgruppen gelten als ***eine grosse Tabelle***. Startet mit 1.
Erzeugung: Neue Verzeichnisse werden in der Blockgruppe angelegt, die von allen Blockgruppen mit ***überdurchschnittlich vielen freien Inodes*** die ***meisten Blöcke frei*** hat, Dateien in der Blockgruppe des Verzeichnis oder nahen Gruppen. Bestimmung anhand ***Inode-Usage-Bitmaps***.
File-Holes: Bereiche in der Datei, in der ***nur Nullen*** stehen. Ein solcher Block wird ***nicht alloziert***.

11.3. BLOCKGRUPPE

Eine Blockgruppe besteht aus ***mehreren aufeinanderfolgenden Blöcken*** bis zu 8 mal der Anzahl Bytes in einem Block.
Layout: ***Block 0*** *(Kopie des Superblocks)*, ***Block 1 bis n*** *(Kopie der Gruppendeskriptorentabelle)*, ***Block $n+1$*** *(Block-Usage-Bitmap mit einem Bit je Block der Gruppe)*, ***Block $n+2$*** *(Inode-Usage-Bitmap mit einem Bit je Inode der Gruppe)*, ***Block $n+3$ bis $n+m+2$*** *(Tabelle aller Inodes in dieser Gruppe)*, ***Block $n+m+3$ bis Ende der Gruppe*** *(Blöcke der eigentlichen Daten)*
Superblock: Enthält ***alle Metadaten*** über das Volume *(Anzahlen, Zeitpunkte, Statusbits, Erster Inode, …)*. Immer an Byte 1024, da möglicherweise Bootdaten davor.
Sparse Superblock: Kopien des Superblocks werden nur in Blockgruppe 0, 1 und allen reinen Potenzen von 3, 5 oder 7 gehalten *(Sehr hoher Wiederherstellungsgrad, aber deutlich weniger Platzverbrauch)*.
Gruppendeskriptor: 32 Byte ***Beschreibung einer Blockgruppe***. *(Blocknummer des Block-Usage-Bitmaps, Blocknummer des Inode-Usage-Bitmaps, Nummer des ersten Blocks der Inode-Tabelle, Anzahl freier Blöcke und Inodes in der Gruppe, Anzahl der Verzeichnisse in der Gruppe)*
Gruppendeskriptortabelle: Tabelle mit Gruppendeskriptor pro Blockgruppe im Volume. Folgt direkt auf Superblock(-kopie). $32 \cdot n$ Bytes gross. Anzahl Sektoren $= (32 \cdot n)/\text{Sektorgrösse}$
Verzeichnisse: Enthält ***Dateieinträge*** mit variabler Länge von 8 - 263 Byte *(4B Inode, 2B Eintraglänge, 1B Dateinamenlänge, 1B Dateityp, 0 - 255B Dateiname aligned auf 4B)*. Defaulteinträge: «.» und «..»
Links: Es gibt ***Hard-Links*** *(gleicher Inode, verschiedene Pfade: Wird von verschiedenen Dateieinträgen referenziert)* und ***Symbolische Links*** *(Wie eine Datei, Datei enthält Pfad anderer Datei)*.

11.4. VERGLEICH FAT, NTFS, EXT2

FAT	*Ext2*	*NTFS*
– Verzeichnis enthält alle Daten über die Datei – Datei ist in einem einzigen Verzeichnis – Keine Hard-Links möglich	– Dateien werden durch Inodes beschrieben – Kein Link von der Datei zurück zum Verzeichnis – Hard-Links möglich	– Dateien werden durch File-Records beschrieben – Verzeichnis enthält Namen und Link auf Datei – Link zum Verzeichnis und Name sind in einem Attribut – Hard-Links möglich

12. EXT4

Vergrössert die wichtigen Datenstrukturen, besser für grosse Dateien, erlaubt höhere maximale Dateigrösse. Blöcke werden mit ***Extent Trees*** verwaltet, ***Journaling*** wird eingeführt.

12.1. EXTENTS

Beschreiben ein ***Intervall physisch konsekutiver Blöcke***. Ist 12 Byte gross *(4B logische Blocknummer, 6B physische Blocknummer, 2B Anzahl Blöcke)*. Positive Zahlen = Block initialisiert, Negativ = Block voralloziert. Im Inode hat es in den 60 Byte für direkte und indirekte Block-Adressierung Platz für 4 Extents und einen Header.
Extent Trees: ***Index-Knoten*** *(Innerer Knoten des Baums, besteht aus Index-Eintrag und Index-Block)*, ***Index-Eintrag*** *(Enthält Nummer des physischen Index-Blocks und kleinste logische Blocknummer aller Kindknoten)*, ***Index-Block*** *(Enthält eigenen Tree-Header und Referenz auf Kindknoten)*
Extent Tree Header: Benötigt ab 4 Extents, weil zusätzlicher Block nötig. Ist 12 Bytes gross: Magic Number $F3\,0A_h$ *(2B)*, Anzahl Einträge, die ***direkt*** auf den Header folgen *(2B)*, Anzahl Einträge, die ***maximal*** auf den Header folgen können *(2B)*, Tiefe des Baums *(2B) - (0: Einträge sind Extents, ≥1: Einträge sind Index Nodes)*, Reserviert *(4B)*
Index Node: Spezifiziert einen Block, der ***Extents enthält***. Besteht aus einem Header und den Extents *(max. 340 bei 4 KB Blockgrösse)*. Ab 1360 Extents zusätzlicher Block mit Index Nodes nötig.

12.1.1. Notation

(in)direkte Adressierung	*Extent-Trees*
direkte Blöcke: <Index> ↦ <Blocknummer>	***Indexknoten:*** <Index> ↦ (<Kindblocknummer>, <kleinste Nummer der 1. logischen Blöcke aller Kinder>)
indirekte Blöcke: <indirekter Block>.<Index> ↦ <direkter Block>	***Blattknoten:*** ↦ (<1. logischer Block>, <1. physischer Block>, <Anzahl Blöcke>)
	Header: <Index> ↦ (<Anz. Einträge>, <Tiefe>)

Beispiel-Berechnung: 4MB grosse, konsekutiv gespeicherte Datei, 4KB Blöcke ab Block $10\,00_h$
(In-)direkte Block-Adressierung
4 MB = 2^{22}B, 4 KB = 2^{12}B, $2^{22-12} = 2^{10} = 4\,00_h$ Blöcke von $10\,00_h$ bis $13\,FF_h$
$0 \mapsto 10\,00_h, \quad 1 \mapsto 10\,02_h, \quad ..., \quad B_h \mapsto 10\,0B_h, \quad C_h \mapsto 14\,00_h$ *(indirekter Block, $4\,00_h$ nach Startblock)*
$14\,00_h.0_h \mapsto 10\,0C_h, \quad 14\,00_h.1_h \mapsto 10\,0D_h, \quad ..., \quad 14\,00_h.3\,F3_h \mapsto 13\,FF_h$

Extent Trees
Header: $0 \mapsto (1, 0)$
Extent: $1 \mapsto (0, 10\,00_h, 4\,00_h)$

12.2. JOURNALING

Wenn Dateisystem beim ***Erweitern*** einer Datei ***unterbrochen*** wird, kann es zu ***Inkonsistenzen*** kommen. ***Journaling*** verringert Zeit für Überprüfung von Inkonsistenzen erheblich.
Journal: Datei, in die Daten schnell geschrieben werden können. Bestenfalls 1 Extent.
Transaktion: Folge von Einzelschritten, die gesamtheitlich vorgenommen werden sollten.
Journaling: Daten als Transaktion ins Journal, dann an finale Position schreiben *(committing)*, Transaktion aus dem Journal entfernen.
Journal Replay: Transaktionen im Journal werden nach Neustart noch einmal ausgeführt.
Journal Modi: ***(Full) Journal*** *(Metadaten und Datei-Inhalte ins Journal, sehr sicher aber langsam)*, ***Ordered*** *(Nur Metadaten ins Journal, Dateiinhalte werden immer vor Commit geschrieben)*, ***Writeback*** *(Nur Metadaten ins Journal, beliebige Reihenfolge, nicht sehr sicher aber schnell)*.

13. X WINDOW SYSTEM

Setzt ***Grundfunktionen der Fensterdarstellung***. Ist austauschbar, realisiert Netzwerktransparenz. Plattformunabhängig, legt die GUI-Gestaltung nicht fest.
Programmgesteuerte Interaktion: Benutzer reagiert auf Programm.
Ereignisgesteuerte Interaktion: Programm reagiert auf Benutzer.
Fenster: Rechteckiger Bereich des Bildschirms. Es gibt eine Baumstruktur aller Fenster, der Bildschirm ist die Wurzel *(z.B. Dialogbox, Scrollbar, Button…)*.
Display: Rechner mit Tastatur, Zeigegerät und $1..m$ Bildschirme
X Client: Applikation, die einen Display nutzen will. Kann lokal oder entfernt laufen.
X Server: Softwareteil des X Window System, der ein Display ansteuert. Beim Nutzer.

13.1. GUI ARCHITEKTUR

Nicht nur X Window System, sondern auch ***Window Manager*** *(Verwaltung der sichtbaren Fenster, Umrandung, Knöpfe. Läuft im Client und realisiert Window Layout Policy)* und ***Desktop Manager*** *(Desktop-Hilfsmittel wie Taskleiste, Dateimanager, Papierkorb etc.)*.

13.2. XLIB

Ist das ***C Interface*** für das X Protocol. Wird meist nicht direkt verwendet.
Funktionen: `XOpenDisplay()` *(öffnet Verbindung zum Display, NULL = Wert von `DISPLAY` Umgebungsvariabel)*, `XCloseDisplay()` *(schliesst Verbindung)*, `XCreateSimpleWindow()` *(erzeugt ein Fenster)*, `XDestroyWindow()` *(entfernt ein Fenster & Unterfenster)*, `XMapWindow()` *(bestimmt, dass ein Fenster angezeigt werden soll (unhide))*, `XMapRaised()` *(bringt Fenster in den Vordergrund)*, `XMapSubwindows()` *(zeigt alle Unterfenster an, Expose Event)*, `XUnmapWindow()` *(versteckt Fenster)*, `XUnmapSubwindows()` *(versteckt Unterfenster, `UnmapNotify` Event)*

X Protocol: Legt die ***Formate für Nachrichten*** zwischen X Client und Server fest. ***Requests*** *(Dienstanforderungen, Client → Server)*, ***Replies*** *(Antworten auf Requests, Client ← Server)*, ***Events*** *(Ereignismeldungen, Client ← Server)*, ***Errors*** *(Fehlermeldungen auf vorangegangene Requests, Client ← Server)*
Request Buffer: Nachrichtenpufferung auf der Client Seite. Für ***Effizienz***.
Pufferung bei Ereignissen: Werden beim X Server und beim Client gepuffert. ***Server-Seitig*** berücksichtigt Netzwerkverfügbarkeit, ***Client-Seitige*** hält Events bereit.
X Event Handling: Ereignisse werden vom Client verarbeitet oder weitergeleitet. Muss ***festlegen, welche*** Typen er empfangen will. `XSelectInput()` *(legt fest, welche Events via Event-Masken empfangen werden, z.B. `ExposureMask`)*, `XNextEvent()` *(kopiert den nächsten Event aus dem Buffer)*.

13.3. ZEICHNEN

Ressourcen: Server-seitige Datenhaltung zur Reduktion des Netzwerkverkehrs. Halten Informationen im Auftrag von Clients. Diese identifizieren Informationen mit IDs. Kein Hin- und Herkopieren komplexer Datenstrukturen nötig. *(z.B. Window, Pixmap, Colormap, Font, Graphics-Context)*
Pufferung verdeckter Fensterinhalte: ***Minimal*** *(keine Pufferung)* oder ***Optional*** *(Hintergrundspeicher zum Sichern vorhanden)*
Pixmap: Server-Seitiger ***Grafikspeicher***, wird immer gecached.
X Grafikfunktionen: Bilddarstellung mittels ***Rastergrafik*** und ***Farbtabelle***. Erlauben das Zeichnen von Figuren, Strings und Texten. ***Ziele*** für das Zeichnen können Fenster oder Pixmap sein.
Graphics Context: Legt diverse ***Eigenschaften*** fest, die Systemaufrufe nicht direkt unterstützen *(z.B. Liniendicke, Farben, Füllmuster)*. Client kann mehrere GCs gleichzeitig nutzen.

13.4. FENSTER SCHLIESSEN

Schaltfläche wird vom ***Window Manager*** erzeugt. X weiss ***nichts*** über spezielle Bedeutung der Schaltfläche, der Window Manager schliesst das Fenster. Es gibt ein ***Protokoll*** zwischen Window Manager und Applikation. `ClientMessage` Event mit `WM_DELETE_MESSAGE`.
Atoms: ***ID eines Strings***, der für ***Meta-Zwecke*** benötigt wird. Erspart Parsen der Strings.
Properties: Werden mit jedem Fenster assoziiert. ***Generischer Kommunikations-Mechanismus*** zwischen Applikation und Window Manager.
`WM_PROTOCOLS`: Von X Standard definierte Anzahl an Protokollen, die der Window Manager verstehen soll. Ein Client kann sich für Protokolle ***registrieren***.
`WM_DELETE_WINDOW`: Wird beim Drücken des «x» vom Window Manager an den Client geschickt.

14. MELTDOWN

Meltdown ist eine ***HW-Sicherheitslücke***, die es ermöglicht, den ***gesamten physischen Hauptspeicher auszulesen***. Ein Prozess kann dadurch geheime Informationen anderer Prozesse lesen.
Der Prozessor muss dazu gebracht werden können:
1. aus dem ***geschützten Speicher*** an Adresse a das Byte m_a zu ***lesen***
2. die Information m_a in irgendeiner Form f_a ***zwischenzuspeichern***
3. ***binäre Fragen*** der Form «$f_a \stackrel{?}{=} i$» zu beantworten
4. Von $i = 0$ bis $i = 255$ ***iterieren***: $f_a \stackrel{?}{=} i$
5. Über alle a ***iterieren***

14.1. PERFORMANCE-OPTIMIERUNGEN

Mapping des Speichers in jeden virtuellen Adressraum, Out-of-Order Execution (O3E), Spekulative Ausführung.
Seiteneffekte O3E: Cache weiss nicht, ob Wert spekulativ angefordert wurde und speichert alles. Da Wert als Teil des Tags gespeichert und die ***Zeit gemessen*** werden kann, die ein Speicherzugriff benötigt, kann man herausfinden, ob etwas im Cache ist oder nicht *(Timing Side Channel Attack)*.
Tests: Verschiedene CPUs *(Intel, einige ARMs, keine AMDs)* und verschiedene OS *(Linux, Windows 10)* sind betroffen. ***Geschwindigkeit*** bis zu 500 KB pro Sekunde bei 0.02% Fehlerrate.
Einsatz: Auslesen von Passwörtern, Zugriff auf andere Dockerimages. Nachweis schwierig.
Gegenmassnahmen: ***Kernel page-table isolation «KAISER»:*** verschiedene Page Tables für Kernel- bzw. User-Mode. Nachteil: System wieder langsam.
Spectre: Gleiches Ziel, verwendet jedoch ***Branch Prediction*** mit spekulativer Ausführung. Branch Prediction wird nicht per Prozess ***unterschieden***. Alle Prozesse, die auf dem selben Prozessor laufen, verwenden die ***selben Vorhersagen***. Ein Angreifer kann damit den Branch Predictor ***für einen anderen Prozess «trainieren»***. Der ***Opfer-Prozess*** muss zur Kooperation ***«gezwungen»*** werden, indem im verworfenen Branch auf Speicher zugegriffen wird. Nicht leicht zu fassen, aber auch nicht leicht zu implementieren.